

# XÂY DỰNG CÔNG CỤ LẮNG NGHE MẠNG XÃ HỘI BẰNG HỌC SÂU

**Hội Đồng:**

**Giảng Viên Hướng Dẫn:**

**Giảng Viên Phản Biện:**

**Thư Ký Hội Đồng:**

**Sinh Viên:**

Hội Đồng 2 Đồ Án Chuyên Ngành

Tiến sĩ Nguyễn An Khương

Thạc sĩ Trần Huy

Thạc sĩ Trần Hồng Tài

Lâm Tấn Thịnh - 2110559

*Thành phố Hồ Chí Minh, 10/2025*

# NỘI DUNG

1. Giới Thiệu
2. Công Trình Và Công Cụ Liên Quan
3. Kiến Thức Chuẩn Bị
4. Thiết Kế Và Hiện Thực
5. Đánh Giá Công Cụ
6. Tổng Kết

# 1. Giới Thiệu

# 1.1 Bối Cảnh & Động Lực

THÁNG 2 / 2025


KHO DỮ LIỆU NGƯỜI DÙNG KHỔNG LỒ

5.24 TỶ

NGƯỜI DÙNG MẠNG XÃ HỘI



Digital 2025: Global Overview Report



**Mạng xã hội là trở thành kênh giao tiếp trọng yếu giữa doanh nghiệp và người tiêu dùng.**

**LẮNG NGHE MẠNG XÃ HỘI**

Người dùng tạo ra khối lượng lớn bài viết & bình luận chứa insight về nhu cầu, quan điểm, hành vi khách hàng.

**Từ đó định hướng truyền thông, phân tích đối thủ và cải thiện sản phẩm.**

## 1.2 Mục Tiêu

**Mục Tiêu Tổng Quát:** Xây dựng công cụ Social Listening tiếng Việt có khả năng thu thập, xử lý và phân tích dữ liệu mạng xã hội tự động, hỗ trợ doanh nghiệp và cá nhân khai thác insight.

### **Mục Tiêu Chi Tiết:**

- Thu thập dữ liệu tự động từ các nền tảng: Facebook, LinkedIn, X (Twitter), YouTube, Google SERP không cần đăng nhập.
- Tích hợp RAG để hỏi – đáp thông minh dựa trên dữ liệu đã thu thập.
- Tinh chỉnh và so sánh các mô hình phân tích cảm xúc.
- Phát triển giao diện web cho nhập từ khóa/URL và quản lý thu thập.
- Đánh giá hiệu quả công cụ.



## 1.3 Phạm Vi

-  Tập trung vào lĩnh vực công nghệ trên mạng xã hội.
-  .Chỉ tập trung vào phân tích văn bản.
-  Phân tích ngôn ngữ tiếng Việt.


## 1.4 Thách Thức & Giải Pháp

- Hạn chế truy cập mạng xã hội → Kết hợp đảo ngược API, trình duyệt tự động và proxy xoay vòng để tránh bị chặn IP, CAPTCHA.
- Dữ liệu phi cấu trúc & nhiễu cao → Tiền xử lý.
- Tiếng lóng, viết tắt, lỗi chính tả. → Fine-tune mô hình.
- Đánh giá RAG khó chuẩn hóa → Kết hợp nhiều metric và dùng LLM-as-a-Judge để kiểm thử chất lượng.

## **2. Công Trình Và Công Cụ Liên Quan**


## 2. Công Trình Và Công Cụ Liên Quan

- Phần lớn các công cụ lắng nghe mạng xã hội hiện nay chỉ trình bày ở dạng dashboard mà không có RAG.



## 2. Công Trình Và Công Cụ Liên Quan

- ChatGPT, Gemini, Claude, LLaMA hỗ trợ hội thoại & tìm kiếm thông tin nhưng không truy cập trực tiếp mạng xã hội (trừ Grok có thể lấy dữ liệu từ X). Biểu tượng Facebook tạo cảm giác ChatGPT thật sự truy cập được Facebook.



Hình 2.1: Khả năng tìm kiếm của GPT.

## 2. Công Trình Và Công Cụ Liên Quan

- AI Agent & MCP DevTools: Không Đủ Khả Năng Để Web Scraping.
  - Cấu trúc DOM phức tạp & khó đọc.
  - Giới hạn xử lý & truy xuất dữ liệu: Lượng request quá lớn và số lượng token AI có thể xử lý không đủ để đọc và phân tích toàn bộ nội dung.

```
▼<div class="x9f619 x1n2onr6 x1ja2u2z">
  ▼<div class="x78zum5 xdt5ytf x1n2onr6 x1ja2u2z"> flex
    ▼<div class="x78zum5 xdt5ytf x1n2onr6 xat3117 xxzkxad"> flex
      <!--$-->
      ▼<div class="x78zum5 xdt5ytf x1t2pt76 x1n2onr6 x1ja2u2z x10cihs4"> flex
        <!--$-->
        ▼<div class="x9f619 x1ja2u2z x78zum5 x2lah0s x1n2onr6 x156j7k x1qjc9v5 xozqiw3 x1q0g3np x1t2pt76 x17upfok"> flex
          ▼<div class="x9f619 x1ja2u2z x78zum5 x1n2onr6 x1r8uery x1iyjqo2 xs83m0k xeuugli x1qughib x1cy8zh1 xozqiw3 x1q0g3np xylbxtu x1t2pt76 xornbnt"> flex
            <!--$-->
            ▶<div aria-label="Lỗi tắt" role="navigation" class="x9f619 x1ja2u2z xnp8db0 x112wk31 xnjgh8c xxc7z9f x1t2pt76 x1u2d2a2 x6ikm8r x10wlt62 x1xzcwzws x7wzq59 xxzkxad x9e5oc1">...</div>
          <!--/$-->
        <!--/$-->
      <!--/$-->
    <!--/$-->
  <!--/$-->
<!--/$-->
```

Hình 2.2: Cấu trúc DOM phức tạp của Facebook.


# 3. Kiến Thức Chuẩn Bị

### 3. Kiến Thức Chuẩn Bị

- Nền tảng Web & Thu thập dữ liệu.
- Học sâu & Phân tích cảm xúc.
- Retrieval-Augmented Generation (RAG).


# 4. Thiết Kế Và Hiện Thực

# 4.1 Kiến Trúc Tổng Thể



Hình 4.1: Kiến trúc tổng thể.

## 4.2 Kiến Trúc RAG



Hình 4.2: Kiến trúc RAG.

# 4.4 Quy Trình Hiện Thực Web Scraping Facebook


- **Google SERP Bypass:** Tìm Facebook Group / Profile qua Google.
- **Session & Cookie Capture:** Dùng Selenium / Playwright + undetected\_chromedriver để tự động lấy session token & cookies.
- **Sử dụng Proxy Xoay IP:** Luân phiên địa chỉ IP nhằm tránh rate limiting và giảm nguy cơ bị chặn.
- **Khai thác bài đăng trong nhóm:**
  - **Scrolling:** cuộn trang để load thêm bài viết.
  - **GraphQL:** gọi GroupsCometFeedRegularStoriesPaginationQuery với end\_cursor để phân trang và tải nhiều post.
- **Khai thác bài đăng từ trang cá nhân:**
  - Cần giả lập User-Agent mobile.
  - Truy cập album ảnh → từng ảnh có URL riêng → mở URL, dùng View Page Source tìm post\_id → dùng post\_id dựng permalink bài viết gốc để thu thập nội dung.

# 4.5 Thiết Lập Huấn Luyện Mô Hình Phân Tích Cảm Xúc

- **Mô hình & Tokenization:**
  - DistilBERT Multilingual Cased.
  - Max sequence length: 128 tokens | Padding: max\_length | Truncation: True.
- **Tham số huấn luyện:**
  - Epochs: 3 | Batch size: 16 | Learning rate: 2e-5.
  - Weight decay: 0.01 | Warmup ratio: 0.06 | Gradient accumulation: 1.

# 5. Đánh Giá Công Cụ

# 5.1 So sánh khả năng thu thập dữ liệu với Bright Data



| Tiêu chí                                                  | Đồ án                                    | BrightData                               | Mạng xã hội (tìm kiếm trực tiếp URL)      |
|-----------------------------------------------------------|------------------------------------------|------------------------------------------|-------------------------------------------|
| Truy vết URL bài viết từ url profile                      | Không giới hạn                           | Không giới hạn                           | Giới hạn 1–5 bài viết                     |
| Truy vết URL bài viết từ url group                        | Không giới hạn                           | Không giới hạn                           | Giới hạn 5–10 bài viết                    |
| Thu thập nội dung bài viết và bình luận từ một URL cụ thể | Có thể thực hiện                         | Có thể thực hiện                         | Có thể thực hiện trong phạm vi chính sách |
| Truy vết URL bài viết từ url profile                      | 100 bài viết                             | 100 bài viết                             | 100 bài viết                              |
| Thu thập nội dung bài viết và bình luận từ một URL cụ thể | Khoảng 35 bình luận/bài viết             | Không xem được bình luận                 | Không cho phép xem bình luận              |
| Thu thập danh sách công việc                              | Không giới hạn                           | Không giới hạn                           | Có thể thực hiện trong phạm vi chính sách |
| Thu thập thông tin profile                                | Có thể thực hiện ngoại trừ nội dung post | Có thể thực hiện ngoại trừ nội dung post | Ngoại trừ nội dung post                   |

Bảng 5.1: So sánh khả năng thu thập dữ liệu của công cụ đồ án, BrightData và mạng xã hội dữ liệu công khai.

# 5.1 So sánh khả năng thu thập dữ liệu với Bright Data

| <br><b>YouTube</b><br><br> | Tiêu chí                               | Đồ án          | BrightData     | Mạng xã hội (tìm kiếm trực tiếp URL)      |
|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------|----------------|----------------|-------------------------------------------|
|                                                                                                                                                                                                | Truy vết url video từ url profile      | Không giới hạn | Không giới hạn | Có thể thực hiện trong phạm vi chính sách |
|                                                                                                                                                                                                | Thu thập comment từ url video          | Không giới hạn | Không giới hạn | Có thể thực hiện trong phạm vi chính sách |
|                                                                                                                                                                                                | Thu thập kết quả tìm kiếm theo từ khóa | Không giới hạn | Không giới hạn | Có thể thực hiện trong phạm vi chính sách |

Bảng 5.1: So sánh khả năng thu thập dữ liệu của công cụ đồ án, BrightData và mạng xã hội dữ liệu công khai.

## 5.3 Thu thập dữ liệu đánh giá RAG

- Thu thập ban đầu khoảng 7.000 bài đăng về AI & công nghệ trong group Facebook.
- Lọc chất lượng (lọc 15 tiêu chí) → lấy top 1.000 bài có điểm cao nhất:
  - Chứa từ khóa công nghệ (AI, ChatGPT, Gemini...).
  - Loại bỏ spam, nội dung quá ngắn hoặc vô nghĩa.
  - Từ 1.000 bài đạt hàng đầu, lọc thủ công lại và thu thập thêm khoảng 3.000 bình luận để mở rộng ngữ cảnh.
  - Tạo khoảng 1.100 cặp query–positive bán thủ công: GPT-5 gợi ý câu hỏi, tác giả thực hiện lọc thủ công, kiểm tra và nhận xét độ chính xác từng câu.
- **Nhận xét:** Bộ dữ liệu thu thập được phần lớn là nội dung ngắn, câu hỏi có thể xuất phát từ bài đăng hoặc bình luận.

## 5.4 So Sánh Các Phương Pháp Chunking

| Phương pháp        | MRR          | Coverage     | Coherence    | Recall       | OverallScore |
|--------------------|--------------|--------------|--------------|--------------|--------------|
| Parent_Child       | 0.943        | <b>0.903</b> | <b>0.925</b> | <b>0.954</b> | <b>0.923</b> |
| Hybrid_150w        | 0.957        | 0.894        | 0.863        | 0.953        | 0.897        |
| Fixed_150w         | <b>0.969</b> | 0.889        | 0.863        | 0.946        | 0.896        |
| Semantic_Embedding | 0.944        | 0.878        | 0.849        | 0.937        | 0.882        |

Bảng 5.3: So sánh các phương pháp chunking cho Facebook post và comment ngắn.

- $\text{OverallScore} = 0.15 \times \text{MRR} + 0.35 \times \text{Coverage} + 0.4 \times \text{Coherence} + 0.1 \times \text{Recall}$ .
- Phương pháp parent-child là đạt số điểm cao nhất phù hợp với đặc điểm bộ dữ liệu đã thu thập.

## 5.5 Đánh giá kích thước embedding model

| Mô hình                   | Recall@3     | Q-Doc Similarity | NDCG         | OverallScore |
|---------------------------|--------------|------------------|--------------|--------------|
| E5-Large<br>(1024D, 560M) | 0.510        | 0.920            | <b>0.688</b> | <b>0.704</b> |
| E5-Base<br>(768D, 278M)   | <b>0.511</b> | 0.921            | 0.687        | <b>0.704</b> |
| E5-Small<br>(384D, 118M)  | 0.464        | <b>0.929</b>     | 0.685        | 0.692        |

Bảng 5.4: So sánh hiệu suất ba mô hình E5.

- Overall =  $0.4 \times \text{NDCG} + 0.3 \times \text{Recall@3} + 0.3 \times \text{Q-Doc Similarity}$ .

## 5.6 Đánh giá e5-base và Vietnamese SimCSE

| Mô hình                                | Recall@3     | Q-Doc Similarity | NDCG         | Overall Score |
|----------------------------------------|--------------|------------------|--------------|---------------|
| Vietnamese SimCSE (768D, 136M tham số) | 0.441        | 0.905            | <b>0.865</b> | 0.750         |
| E5-Base (768D, 278M)                   | <b>0.511</b> | <b>0.921</b>     | 0.687        | 0.704         |

Bảng 5.5: So sánh hiệu suất giữa mô hình nhúng đa ngôn ngữ và mô hình chuyên biệt tiếng Việt.

- Overall =  $0.4 \times \text{NDCG} + 0.3 \times \text{Recall@3} + 0.3 \times \text{Q-Doc Similarity}$ .

# 5.7 Đánh Giá Hiệu Năng RAG Tổng Thể

- Sử dụng mô hình Gemini 2.0 Flash-Lite làm thành phần tạo sinh trong hệ thống

| Mô hình Judge    | Faithfulness | Context Recall | Context Precision | Answer Relevance | RAG Score |
|------------------|--------------|----------------|-------------------|------------------|-----------|
| Gemini 2.0 Flash | 0.883        | 0.914          | 0.932             | 0.859            | 0.925     |
| Qwen 2.5-7B      | 0.800        | 0.600          | 0.900             | 0.700            | 0.750     |
| Qwen 2.5-0.5B    | 0.800        | 0.600          | 0.900             | 0.700            | 0.750     |

Bảng 5.6: So sánh kết quả đánh giá RAG bằng các mô hình LLM Judge.

- Mô hình nhỏ như Qwen chưa đủ thông minh để làm LLM-as-a-Judge.
- Cần dùng mô hình lớn để đánh giá đáng tin cậy.



## 5.8 Thu thập dữ liệu phân tích cảm xúc

- Nguồn & khối lượng ban đầu: Thu thập khoảng 11.000 bình luận/đánh giá từ Facebook và Google Play trước khi làm sạch.
- Sau làm sạch & lọc chất lượng:
  - Tiêu cực: 3.386 bình luận (từ nhóm đánh giá 1 sao).
  - Tích cực: 3.183 bình luận (từ nhóm đánh giá 5 sao).
  - Hỗn hợp: 283 bình luận (vừa khen vừa chê).
  - Trung tính: 167 bình luận (từ đánh giá 2–4 sao).
- Xử lý mất cân đối: Gộp hỗn hợp + trung tính thành 1 lớp Trung tính (tổng 450 mẫu) để tránh lớp quá nhỏ gây khó huấn luyện và giúp mô hình học tốt hơn với các trường hợp cảm xúc mơ hồ.

## 5.9 Đánh giá mô hình phân tích cảm xúc

- Mô hình dùng để train: distilbert/distilbert-base-multilingual-cased.

| Tiêu chí  | Hai lớp | Ba lớp |
|-----------|---------|--------|
| Accuracy  | 86.53%  | 83.05% |
| F1-Macro  | 86.52%  | 71.01% |
| Precision | 86.52%  | 73.83% |
| Recall    | 86.55%  | 69.33% |

- Mô hình hai lớp đơn giản, ổn định và phù hợp triển khai thực tế.
- Mô hình ba lớp phản ánh hiện thực tốt hơn nhưng kém hiệu quả do dữ liệu trung tính ít và mất cân bằng, cần bổ sung và cải thiện chất lượng để nâng cao hiệu suất.

# 6. Tổng Kết

## 6. Tổng Kết

- Xây dựng được công cụ Social Listening hỗ trợ thu thập dữ liệu mạng xã hội, hỏi – đáp RAG và phân tích cảm xúc.
- Phân tích được các phương pháp tối ưu để hiện thực và đánh giá hệ thống RAG.
- Thu thập được bộ dữ liệu phục vụ RAG và phân tích cảm xúc tiếng Việt.
- So sánh được tính khả thi giữa mô hình hai lớp và ba lớp trong phân tích cảm xúc, đưa ra khuyến nghị triển khai phù hợp.

# Minh Họa Sản Phẩm

## Facebook

Discover insights about any Facebook page or post

Paste Facebook URL

Analyze

Example: <https://www.facebook.com/tanthinhvnex>

### Recent Page Searches




Việt Nguyễn AI  
38000 followers



### Recent Post Analyses



Hỏi 5 AI khác nhau đoán 1 số bất kì từ 1 đến 50, và cả 5 đều trả lời là 27 🤔  
# \*\*Hỏi 5 AI khác nhau đoán 1 số bất kì từ 1 đến 50, và cả 5 đều trả lời là 27 🤔\*\*...  
Việt Nguyễn AI



**CẢM ƠN CÁC THẦY ĐÃ LẮNG NGHE!**